

Version : 1.0

Date : juillet 2026

Statut : Version finale

Dépôt : <https://github.com/Prosper-BATAMBA/Ghostscrape.git>

Présenté par :
**BATAMBA Samuel Prosper &
M'VILA Vernon**

Supervisé par :
Ingénieur MOUNZEHO

Table des matières

Version : 1.0	1
Table des matières.....	2
1. Introduction	4
1.1 Résumé exécutif	4
1.2 Contexte.....	4
1.3 Problématique.....	5
1.4 Objectifs	5
1.4.1 Objectif principal.....	5
1.4.2 Objectifs spécifiques	5
2. Analyse du besoin.....	6
2.1 Public cible	6
2.1.1 Analystes de données	6
2.1.2 Professionnels du référencement (SEO).....	6
2.1.3 Développeurs web	6
2.1.4 Designers UX/UI.....	6
2.1.5 Chercheurs et étudiants.....	6
2.1.6 Journalistes et analystes	7
2.2 User stories	7
2.2.1 Analyste de données.....	7
2.2.2 Développeur.....	7
2.2.3 Designer UX/UI	7
3. Présentation de la solution	8
3.1 Vision.....	8
3.2 Principe de fonctionnement	8
4. Spécifications Fonctionnelles	9
4.1 Cas d'utilisation	9

4.2 Fonctionnalités	9
4.2.1 Extraction du DOM	9
4.2.2 Export des données	11
Export CSV	11
Export ZIP	11
4.2.3 Communication en temps réel	12
4.2.4 Navigation assistée	12
4.2.5 Résilience et gestion des erreurs	12
5. Architecture Technique	13
5.1 Architecture globale C4 Context	13
5.2 Stack technique	14
5.3 Diagrammes	15
5.3.1 Diagramme d'activité Processus d'extraction	15
5.4 Modèles de données	15
5.4.1 Principes	15
5.5 Sécurité	17
5.5.1 Principes fondamentaux	17
5.5.2 CORS	17
6. Interface et maquettes	18
6.1 Interface d'accueil	18
6.2 Visuel popup	18
6.2.1 Visuel Résultat extraction (mode page complète)	19
6.2.2 Interface mode ciblée	19
6.2.3 Interface mode CSS	20
6.3 Contraintes techniques et risques	21
6.3.1 Contraintes techniques	21
6.3.2 Compatibilité navigateur	22
6.3.3 Dépendances externes	22
7. Matrice des risques	22

1. Introduction

1.1 Résumé exécutif

GhostScrape est une plateforme de web scraping locale, gratuite et open source permettant d'extraire des données structurées depuis des pages web sans écrire de code. L'application repose sur une extension Chrome, un backend FastAPI hébergé (stateless) et un tableau de bord React communiquant en temps réel via WebSocket. Elle vise à simplifier la collecte de données pour les utilisateurs non techniques tout en garantissant la confidentialité des informations grâce à un traitement sur le poste client : les données extraites ne sont jamais persistées sur le backend elles transitent en mémoire vive le temps de la session et sont immédiatement relayées au dashboard.

1.2 Contexte

Avec la croissance du volume de données disponibles sur le Web, la collecte automatisée d'informations est devenue une activité essentielle dans de nombreux domaines tels que la data science, le référencement (SEO), la veille concurrentielle, la recherche académique, le journalisme de données ou encore l'analyse marketing.

Aujourd'hui, deux grandes approches dominent le web scraping :

- La première repose sur des bibliothèques de programmation telles que BeautifulSoup, Scrapy, Selenium, Puppeteer ou Playwright. Bien que puissantes, ces solutions nécessitent des compétences en programmation et le développement de scripts spécifiques pour chaque site à analyser.
- La seconde est constituée de plateformes SaaS proposant des interfaces graphiques facilitant l'extraction des données. Malgré leur simplicité d'utilisation, ces solutions impliquent généralement des coûts d'abonnement, des limitations d'utilisation ainsi que le traitement des données sur des infrastructures distantes, ce qui peut poser des questions de confidentialité.

Dans ce contexte, il existe un besoin pour une solution permettant d'effectuer des extractions de données de manière visuelle, locale, gratuite et sans compétences avancées en développement.

1.3 Problématique

Comment permettre à des utilisateurs ne disposant pas de compétences en programmation d'extraire rapidement des données structurées depuis des pages web, tout en garantissant la confidentialité des données, en supprimant les coûts liés aux

plateformes cloud et en offrant une interface simple permettant d'obtenir des résultats directement exploitables ?

Pour répondre à cette problématique, le projet GhostScrape propose une plateforme de web scraping combinant une extension Chrome (locale), un backend FastAPI hébergé (relais stateless) et un tableau de bord React afin d'offrir une expérience d'extraction visuelle, rapide et sans écriture de code.

1.4 Objectifs

1.4.1 Objectif principal

Concevoir une plateforme de web scraping permettant d'extraire des données structurées depuis des pages web sans programmation, avec une extension locale et un backend relayé hébergé (stateless les données ne sont jamais persistées sur le serveur).

1.4.2 Objectifs spécifiques

- Réduire le temps nécessaire à la collecte de données web.
- Rendre le web scraping accessible aux utilisateurs non techniques.
- Garantir la confidentialité des données : l'extension scrappe le DOM réel du navigateur, les données transitent par le backend sans être persistées.
- Permettre l'extraction de plusieurs types de contenus (textes, images, liens, tableaux, métadonnées, etc.).
- Fournir des résultats directement exploitables grâce aux exports CSV et ZIP.
- Assurer une communication temps réel entre les différents composants de l'application via WebSocket.
- Concevoir une architecture modulaire facilitant les évolutions futures.

2. Analyse du besoin

2.1 Public cible

GhostScrape s'adresse aux utilisateurs ayant besoin d'extraire des données depuis des pages web de manière simple, rapide et locale, sans développer de scripts spécifiques. L'application vise aussi bien les professionnels que les étudiants ou les particuliers manipulant régulièrement des informations issues du Web.

Les principaux utilisateurs ciblés sont les suivants :

2.1.1 Analystes de données

Les analystes de données utilisent GhostScrape pour collecter rapidement des jeux de données provenant de sites web afin de les exploiter dans des outils tels qu'Excel, Power BI, Python ou R. L'application leur permet de constituer des datasets sans avoir à écrire de scripts de scraping.

2.1.2 Professionnels du référencement (SEO)

Les spécialistes du référencement peuvent extraire les titres, métadonnées, liens, images ou structures HTML d'un site afin de réaliser des audits SEO, des analyses concurrentielles ou des études de contenu.

2.1.3 Développeurs web

Les développeurs utilisent GhostScrape pour tester rapidement des sélecteurs CSS, inspecter la structure du DOM, récupérer des éléments HTML ou générer des jeux de données destinés à leurs applications.

2.1.4 Designers UX/UI

Les designers peuvent récupérer facilement des images, des éléments graphiques ou des exemples d'interfaces provenant de sites web afin de constituer une base d'inspiration ou d'analyser les tendances de conception.

2.1.5 Chercheurs et étudiants

Les étudiants et les chercheurs peuvent automatiser la collecte de données publiques nécessaires à leurs travaux académiques, mémoires ou projets de recherche, sans disposer de compétences avancées en programmation.

2.1.6 Journalistes et analystes

Les journalistes de données, consultants et analystes peuvent utiliser GhostScrape pour extraire rapidement des informations publiques destinées à des études, des rapports ou des travaux de veille.

2.2 User stories

2.2.1 Analyste de données

- Je veux exporter les données extraites au format CSV afin de les exploiter directement dans Excel ou Power BI.
- Je veux sélectionner uniquement les types de données à extraire afin de récupérer uniquement les informations utiles.
- Je veux prévisualiser les résultats avant l'export afin de vérifier la qualité des données collectées.
- Je veux retrouver mes extractions précédentes afin de réutiliser mes données sans recommencer l'extraction.
- Je veux connaître l'état de la connexion avec l'extension afin de savoir si une extraction peut être lancée.

2.2.2 Développeur

- Je veux tester un sélecteur CSS afin de vérifier rapidement qu'il cible les bons éléments.
- Je veux extraire les éléments correspondant à un sélecteur personnalisé afin de récupérer une structure HTML spécifique.
- Je veux consulter les attributs HTML des éléments extraits afin de faciliter le débogage et l'inspection du DOM.
- Je veux obtenir les résultats dans un format exploitable par mes outils afin d'automatiser des traitements complémentaires.

2.2.3 Designer UX/UI

- Je veux télécharger toutes les images d'une page afin de constituer une bibliothèque d'inspiration.
- Je veux récupérer les ressources visuelles en un seul export afin de gagner du temps lors de ma veille graphique.
- Je veux récupérer les ressources visuelles en un seul export afin de gagner du temps lors de ma veille graphique.

3. Présentation de la solution

3.1 Vision

"Naviguez, sélectionnez, téléchargez."

GhostScrape a pour ambition de démocratiser le web scraping en proposant une solution gratuite, locale et intuitive permettant d'extraire des données structurées depuis des pages web sans écrire une seule ligne de code. L'application offre une interface visuelle simple tout en garantissant la confidentialité des données grâce à un traitement sur le poste client.


3.2 Principe de fonctionnement

GhostScrape fonctionne avec **quatre modes d'extraction** :

- **Mode page complète (FullPage)** : ce mode permet à l'utilisateur de scraper l'entièreté de la page en récupérant les principaux éléments (titres, liens, paragraphes, images).
- **Mode extraction ciblée (DataTypes)** : ce mode permet à l'utilisateur de sélectionner un type d'élément précis parmi ceux présents (images, titres, liens, paragraphes, listes, tableaux, métadonnées, données structurées).
- **Mode sélecteur CSS (CssSelector)** : permet de scraper la page selon une balise ou un sélecteur CSS saisi librement.
- **Mode historique (HistoryView)** : permet de consulter l'historique des 20 dernières sessions d'extraction avec reprise des résultats et ré-export.


Le flux de données suit ce chemin :

Flux de données – GhostScape



4. Spécifications Fonctionnelles

4.1 Cas d'utilisation



4.2 Fonctionnalités

4.2.1 Extraction du DOM

GhostScape propose quatre modes d'extraction adaptés à différents besoins d'utilisation.

Mode Page complète (FullPage)

Ce mode réalise une extraction complète du contenu de la page web en récupérant automatiquement :

- Les titres (h1 à h6)
- Les paragraphes

- Les liens (URL d'origine, URL résolue, distinction entre liens internes et externes)
- Les images (attributs src, srcset, data-src, images d'arrière-plan CSS, dimensions, attributs HTML)

Mode Extraction ciblée (DataTypes)

Ce mode permet à l'utilisateur de sélectionner uniquement les catégories de données à extraire parmi les suivantes :

- Images
- Titres
- Liens
- Paragraphes
- Listes
- Tableaux HTML
- Métadonnées (Open Graph et Twitter Cards)
- Données structurées (JSON-LD et Microdata)

Mode Sélecteur CSS (CssSelector)

Ce mode permet de saisir un sélecteur CSS personnalisé afin d'extraire des éléments spécifiques d'une page.

Avant l'extraction, l'utilisateur peut :

- Tester le sélecteur en temps réel
- Visualiser le nombre d'éléments correspondants
- Prévisualiser les éléments sélectionnés

Les données récupérées comprennent notamment :

- Le texte de l'élément
- Le code HTML brut
- Les attributs HTML
- Les liens (href)

Mode Historique (HistoryView)

Ce mode permet de consulter les vingt dernières sessions d'extraction.

Pour chaque session, l'utilisateur peut :

- Consulter les résultats précédents
- Réexporter les données

- Supprimer une session
- Supprimer l'ensemble de l'historique

4.2.2 Export des données

GhostScrape propose deux formats d'export.

Export CSV

Les données tabulaires sont exportées au format **CSV UTF-8 avec BOM**, garantissant une compatibilité directe avec :

- Microsoft Excel
- Power BI
- Python
- R
- Tout autre outil compatible CSV

Export ZIP

Les résultats peuvent également être exportés sous la forme d'une archive ZIP organisée par type de données.

L'archive contient notamment les dossiers suivants :

- images
- headings
- links
- paragraphes
- lists
- tables
- metadata
- structured-data

Chaque dossier peut contenir :

- des fichiers JSON ;
- des fichiers texte (TXT) ;
- les images extraites.

4.2.3 Communication en temps réel

GhostScrape utilise une communication temps réel basée sur le protocole WebSocket sécurisé (WSS).

Les principales fonctionnalités sont les suivantes :

- Affichage de l'état de la connexion (connecté / déconnecté)
- Reconnexion automatique en cas de perte de connexion
- Backoff exponentiel (de 200 ms jusqu'à 5 secondes)
- Affichage instantané des résultats d'extraction dans le tableau de bord

4.2.4 Navigation assistée

Le tableau de bord permet de contrôler directement la navigation du navigateur.

L'utilisateur peut :

- Saisir une URL depuis le dashboard
- Ouvrir automatiquement cette URL dans un nouvel onglet Chrome
- Fermer automatiquement l'onglet précédemment utilisé
- Suivre dynamiquement l'onglet actif afin d'effectuer les extractions sur la bonne page

4.2.5 Résilience et gestion des erreurs

Afin d'assurer la robustesse des extractions, GhostScrape met en œuvre plusieurs mécanismes de tolérance aux pannes.

Ces mécanismes comprennent notamment :

- Un délai maximal de 30 secondes par extraction
- La possibilité d'annuler une extraction en cours
- Trois tentatives automatiques en cas d'échec
- Une stratégie de backoff exponentiel (1 s, 2 s puis 4 s)
- La détection automatique des pages inaccessibles ou protégées (erreur 403, Cloudflare, contenu vide, etc.)
- Un mécanisme de bascule (fallback) vers le backend lorsque l'extraction directe n'est pas possible

4.3 Exigences non fonctionnelles


Exigence	Description
----------	-------------

Disponibilité	L'extension fonctionne en local ; le backend est hébergé sur Render (free tier, peut s'endormir après 15 min d'inactivité UptimeRobot ping /health toutes les 5 min)
Performances extraction	Extraction full page (500 éléments) terminée en moins de 2 s
Performances reconnexion	Reconnexion WebSocket en moins de 5 s (worst case)
Volume de données	Export ZIP limité à 50 Mo (contrainte mémoire navigateur)
Historique	20 sessions maximum en localStorage, politique FIFO
Accessibilité	Interface utilisable sans connaissance en programmation
Résilience	Reconnexion automatique de tous les composants en cas de perte de connexion
Isolation session	Chaque onglet du dashboard possède un session_id unique ; le backend route les messages vers la bonne session uniquement

5. Architecture Technique

5.1 Architecture globale C4 Context

System Context GhostScrape




5.2 Stack technique

Couche	Technologie	Version	Rôle
Extension	Chrome MV3 (Manifest V3)		Content script + service worker + offscreen document + popup
Frontend	React	18.3.1	Interface utilisateur (dashboard)
Bundler	Vite	5.4.11	Build et hot-reload en développement
CSS	Tailwind CSS	3.4.17	Styles utilitaires
Backend	Python / FastAPI	3.12 / 0.115+	Relais WebSocket + health check
Backend	BeautifulSoup / lxml	4.12.3 / 5.3.0	Parsing HTML (scraping statique)
Backend	Playwright	1.49.1	Scraping navigateur réel (JS, SPA)
Backend	playwright-stealth	1.0.6	Anti-détection (23 évasions)
Backend	httpx	0.28.1	Client HTTP (scraping statique)
Backend	orjson	3.10.12	JSON rapide
Backend	Pydantic	2.10.4	Validation des messages WebSocket
ZIP	JSZip	3.10.1	Génération d'archives ZIP côté client
Infrastructure	Docker		Conteneurisation du backend
Infrastructure	Nginx		Reverse proxy (DNS resolver pour Docker)
Infrastructure	Render		Hébergement backend (Docker)
Infrastructure	Netlify		Hébergement frontend (fichiers statiques)
Infrastructure	UptimeRobot		Keepalive backend (ping /health toutes les 5 min)
Infrastructure	GitHub		Code source + distribution extension ZIP

5.3 Diagrammes

5.3.1 Diagramme d'activité Processus d'extraction



5.4 Modèles de données

5.4.1 Principes

- **Aucune base de données côté serveur** : le backend est un relais stateless, il ne stocke aucune donnée. Les données extraites transitent en mémoire vive le temps de la session et sont immédiatement relayées au dashboard.
- **Validation côté backend** : via Pydantic (message WebSocket).

- **Persistance côté client** : localStorage pour l'historique des sessions, mémoire vive pour les résultats en cours.
- **Isolation par session** : chaque onglet du dashboard possède un session_id unique stocké en sessionStorage. Le backend route les messages uniquement vers la session concernée (pas de broadcast entre utilisateurs).

Entité	Attributs principaux
Session d'extraction (ScrapeSession)	id, modeId, url, title, timestamp, data
Image (ImageResult)	src, alt, width, height, type, tag, html, attrs
Lien (LinkResult)	text, html, attrs, tag, href, resolvedUrl, isInternal
Titre (HeadingResult)	h1, h2, h3, h4, h5, h6
Tableau (TableResult)	caption, headers, rows
Liste (ListResult)	type, items
Métadonnées (MetadataResult)	title, description, keywords, og, twitter
Données structurées (StructuredDataItem)	type, data, count, examples (contenant type et props [name, value])

L'absence de base de données est un choix délibéré :

- **Simplicité** : pas d'installation de PostgreSQL, Redis ou autre service.
 - **Confidentialité** : aucune donnée persistée côté serveur = zéro risque de fuite.
 - **Performance** : pas de latence réseau pour des requêtes DB.
- Déploiement** : le backend se lance en une commande (uvicorn), aucune configuration requise.
- **Évolutivité** : si une persistance devient nécessaire (utilisateurs, authentification), une migration vers une base de données est possible sans refonte architecturale.

5.5 Sécurité

5.5.1 Principes fondamentaux

- Zéro donnée persistée : aucune donnée extraite n'est stockée sur le backend elle transite en mémoire vive et est immédiatement relayée au dashboard.
- Zéro exécution de code utilisateur : les sélecteurs CSS sont des chaînes, jamais exécutés comme code.
- Zéro téléchargement automatique : l'utilisateur clique toujours pour télécharger.
- Sandbox MV3 : le content script est isolé de la page par Chrome.
- WSS/TLS en production : les communications WebSocket entre le dashboard, l'extension et le backend sont chiffrées (WSS).
- Isolation des sessions : chaque onglet du dashboard possède un `session_id` unique. Le backend ne relaye les résultats qu'à la session concernée.

5.5.2 CORS

Aucun mot de passe stocké.

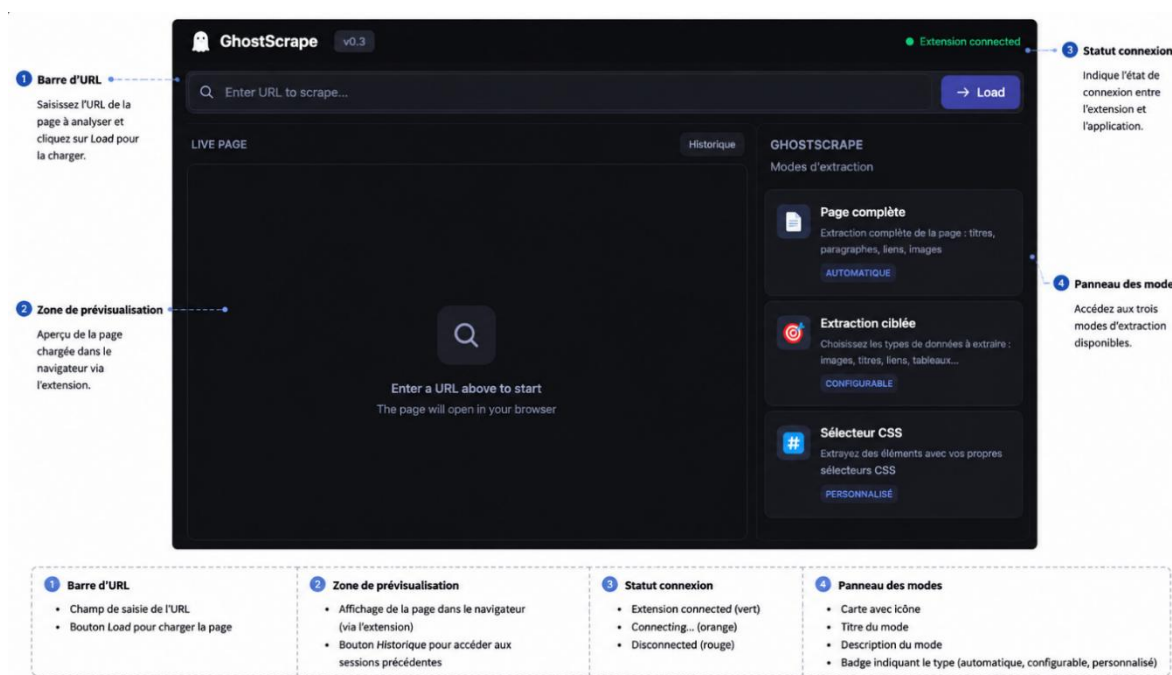
Aucun token, clé API ou secret.

Aucune persistance backend (tout est in-memory ou localStorage).


Le backend autorise les origines suivantes : `http://localhost:3000` , `https://ghostscrape-front.netlify.app` .

6. Interface et maquettes


6.1 Interface d'accueil




6.2 Visuel popup



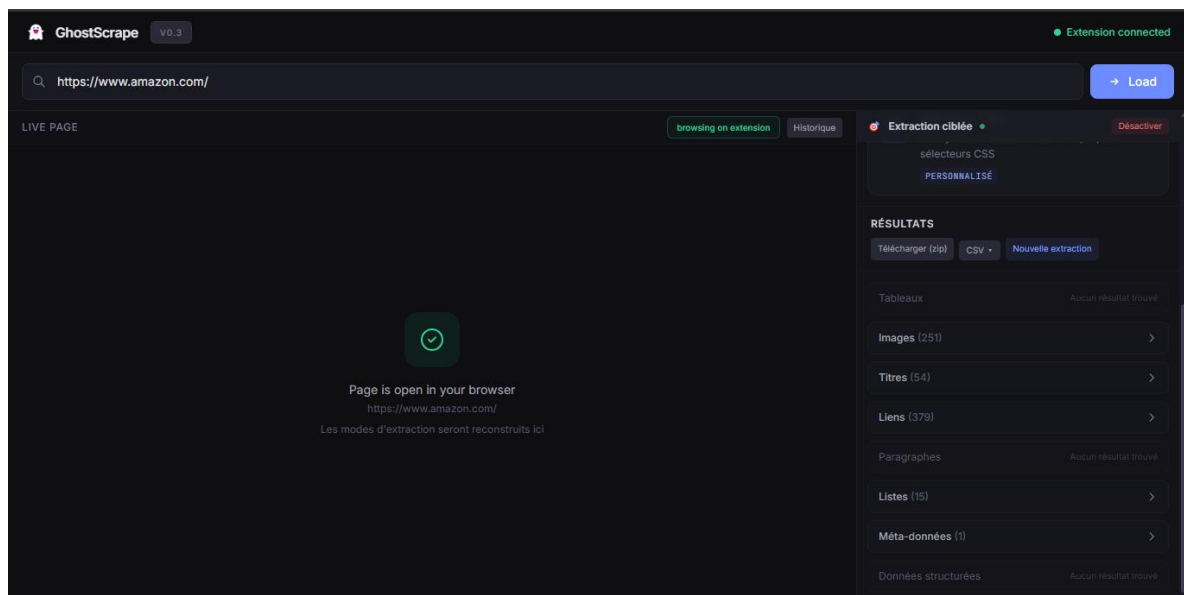
6.2.1 Visuel Résultat extraction (mode page complète)




6.2.2 Interface mode ciblée



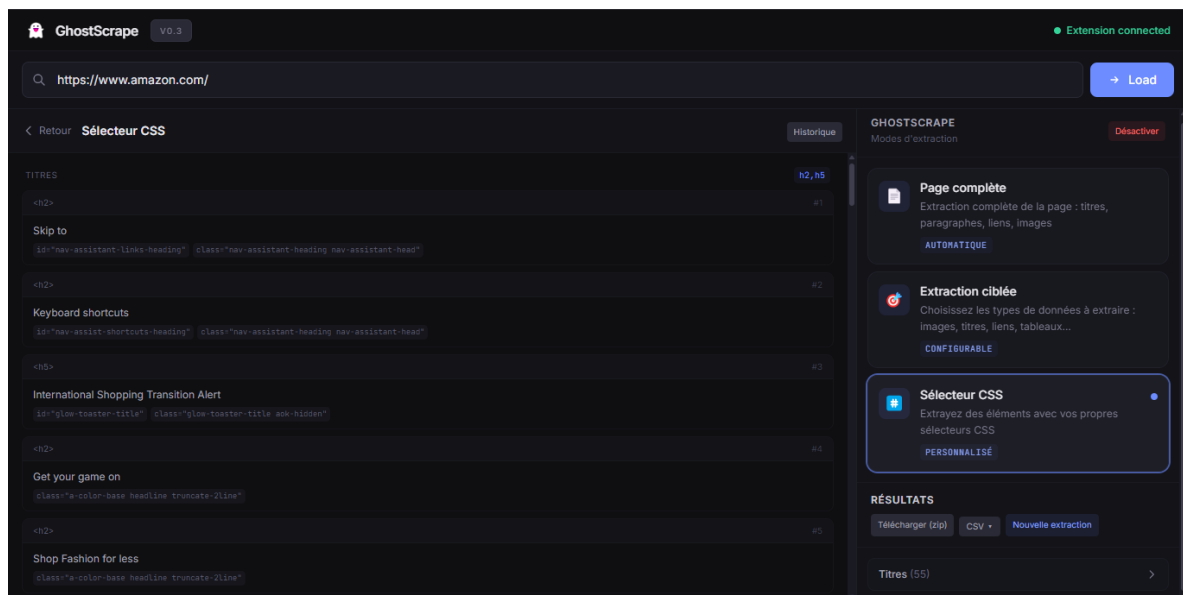
Résultat extraction (mode ciblé)



6.2.3 Interface mode CSS



Résultats extraction (mode CSS)



6.3 Contraintes techniques et risques

6.3.1 Contraintes techniques

Contrainte	Détail
Manifest V3	Pas de <code>eval()</code> , pas de <code>Function()</code> , pas de script distant
Offscreen API	Chrome ≥ 116 , document caché pour WebSocket
WebSocket	Pas de WebSocket dans un service worker $\rightarrow$ offscreen obligatoire
Content script	Isolé du contexte de la page (sandbox MV3)
CORS	Les <code>fetch()</code> depuis <code>content.js</code> sont soumis aux CORS de la page
localStorage	Limité à ~5-10 Mo selon le navigateur
Service worker	Tué après ~30 s d'inactivité $\rightarrow$ keepalive nécessaire
Port Chrome	1 seule connexion par port de message runtime
Render free tier	Backend s'endort après 15 min d'inactivité $\rightarrow$ première connexion WebSocket peut prendre 30-60s (cold start). UptimeRobot ping /health toutes les 5 min pour atténuer

6.3.2 Compatibilité navigateur

Navigateur	Support	Raison
Google Chrome $\geq$ 116	Complet	MV3, Offscreen API
Microsoft Edge $\geq$ 116	Complet	Basé sur Chromium
Firefox	Non	MV3 non supporté
Safari	Non	Pas de MV3

6.3.3 Dépendances externes

Dépendance	Risque	Mesure
Chrome MV3 (offscreen API)	Google modifie ou supprime l'API	Surveiller ChromeStatus, planifier migration Playwright (V0.5)
React 18	Fin de support	Migration vers React 19 (LTS suivante)
FastAPI / Pydantic	Breaking changes	Tests automatisés, CI GitHub
JSZip	Vulnérabilité	Mise à jour via npm audit
playwright-stealth	Incompatibilité avec nouvelle version Chrome	Suivre les releases, fallback httpx
Render free tier	Changement des conditions du free tier	Prévoir budget \$7/mo pour plan Starter

7. Matrice des risques

Risque	Probabilité	Impact	Niveau	Atténuation
Google modifie les APIs MV3	Forte	Élevé	Critique	Planifier migration Playwright comme moteur principal (V0.5)

(offscreen, service worker)				
Render free tier endort le backend après inactivité	Élevée	Moyen	Moyen	UptimeRobot ping /health toutes les 5 min ; ping /health par l'extension avant connexion WS
Session isolation cassée (broadcast des résultats à tous les dashboards)	Faible	Critique	Élevé	Routage par _session_id côté backend ; test unitaire dédié
playwright-stealth incompatible avec une mise à jour Chrome	Moyenne	Élevé	Élevé	Suivre les releases de playwright-stealth ; fallback httpx pour pages statiques
Extension ZIP corrompu ou fichier manquant	Faible	Élevé	Moyen	Tester manuellement après chaque mise à jour ; script de validation CI
Déploiement Netlify ou Render cassé	Faible	Élevé	Moyen	Vérifier l'état du déploiement avant de merge ; notification Slack/e-mail